最小二乘法讲义计划

1　一元最小二乘拟合：从平方误差到正规方程

定义 1.1. 设有 $n \geq 2$ 个观测点 (x_i, y_i)，其中 $x_i, y_i \in \mathbb{R}$，$i = 1, \ldots, n$。用直线

$$\hat{y}_i = a + bx_i$$

拟合被解释变量 y_i，其中 $a, b \in \mathbb{R}$ 分别为截距参数和斜率参数。定义平方误差目标函数为

$$S(a, b) = \sum_{i=1}^{n} \big[y_i - (a + bx_i)\big]^2. \tag{1}$$

一元最小二乘估计 $(\hat{a}, \hat{b})$ 是使 $S(a, b)$ 在 $\mathbb{R}^2$ 上达到最小值的参数对。

定义 1.2. 对给定的参数 a, b，第 i 个观测的残差定义为观测值与拟合值之差：

$$e_i = y_i - (a + bx_i). \tag{2}$$

当参数取最小二乘估计 $(\hat{a}, \hat{b})$ 时，记

$$\hat{y}_i = \hat{a} + \hat{b}x_i, \qquad \hat{e}_i = y_i - \hat{y}_i.$$

此时平方误差目标函数的最小值为残差平方和 $\sum_{i=1}^{n} \hat{e}_i^2$。

定理 1.3. 设 $x_i, y_i \in \mathbb{R}$，且

$$\sum_{i=1}^{n} (x_i - \bar{x})^2 > 0, \qquad \bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i, \qquad \bar{y} = \frac{1}{n}\sum_{i=1}^{n} y_i.$$

则平方误差函数 $S(a, b)$ 在 $\mathbb{R}^2$ 上具有唯一最小点 $(\hat{a}, \hat{b})$。该最小点满足正规方程

$$\sum_{i=1}^{n} \big[y_i - (\hat{a} + \hat{b}x_i)\big] = 0, \qquad \sum_{i=1}^{n} x_i \big[y_i - (\hat{a} + \hat{b}x_i)\big] = 0, \tag{3}$$

并且

$$\hat{b} = \frac{\sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n} (x_i - \bar{x})^2}, \qquad \hat{a} = \bar{y} - \hat{b}\bar{x}.$$

证明. 将 $S(a, b)$ 展开得

$$S(a, b) = \sum_{i=1}^{n} \big[y_i - a - bx_i\big]^2.$$

对 a 和 b 分别求偏导，得到

$$\frac{\partial S}{\partial a} = -2\sum_{i=1}^{n}\big[y_i - a - bx_i\big], \qquad \frac{\partial S}{\partial b} = -2\sum_{i=1}^{n} x_i\big[y_i - a - bx_i\big].$$

因此，最小点必须满足式 (3)。第一条正规方程给出

$$n\hat{a} + \hat{b}\sum_{i=1}^{n} x_i = \sum_{i=1}^{n} y_i,$$

从而

$$\hat{a} = \bar{y} - \hat{b}\bar{x}.$$

把它代入第二条正规方程，并利用

$$\sum_{i=1}^{n}(x_i - \bar{x}) = 0, \qquad \sum_{i=1}^{n}(y_i - \bar{y}) = 0,$$

可得

$$\hat{b}\sum_{i=1}^{n}(x_i - \bar{x})^2 = \sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}).$$

由于分母严格为正，故 $\hat{b}$ 唯一确定，随后 $\hat{a}$ 也唯一确定。

下面验证由上述公式给出的 $(\hat{a}, \hat{b})$ 确实满足正规方程。对第一条，有

$$\sum_{i=1}^{n}\big[y_i - (\hat{a} + \hat{b}x_i)\big] = \sum_{i=1}^{n} y_i - n\hat{a} - \hat{b}\sum_{i=1}^{n} x_i = n\bar{y} - n(\bar{y} - \hat{b}\bar{x}) - \hat{b}n\bar{x} = 0.$$

对第二条，利用 $\sum_{i=1}^{n}(x_i - \bar{x}) = 0$ 和 $\sum_{i=1}^{n}(y_i - \bar{y}) = 0$，有

$$\sum_{i=1}^{n} x_i\big[y_i - (\hat{a} + \hat{b}x_i)\big] = \sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}) - \hat{b}\sum_{i=1}^{n}(x_i - \bar{x})^2 = 0,$$

最后一步由 $\hat{b}$ 的定义得到。因此 $(\hat{a}, \hat{b})$ 满足式 (3)。

为说明这是唯一的全局最小点，令 $u = a - \hat{a}$，$v = b - \hat{b}$。由于 $(\hat{a}, \hat{b})$ 满足正规方程，直接展开平方项可得

$$S(a, b) = S(\hat{a}, \hat{b}) + \sum_{i=1}^{n}(u + vx_i)^2.$$

再将 $x_i = (x_i - \bar{x}) + \bar{x}$ 代入，并令 $w = u + v\bar{x}$，得到

$$\sum_{i=1}^{n}(u + vx_i)^2 = nw^2 + v^2\sum_{i=1}^{n}(x_i - \bar{x})^2 \geq 0.$$

当且仅当 $w = 0$ 且 $v = 0$ 时等号成立；由此 $u = 0$。所以 $(\hat{a}, \hat{b})$ 是唯一最小点。 □

定理 1.4. *在定理 (3) 的条件下，最小二乘拟合直线经过样本均值点 $(\bar{x}, \bar{y})$，即*

$$\hat{y}(\bar{x}) = \hat{a} + \hat{b}\bar{x} = \bar{y}.$$

等价地，含截距的一元最小二乘拟合满足

$$\sum_{i=1}^{n}\hat{e}_i = 0.$$

证明. 由定理 (3) 给出的截距公式，

$$\hat{a} = \bar{y} - \hat{b}\bar{x}.$$

因此

$$\hat{a} + \hat{b}\bar{x} = \bar{y}.$$

另一方面，第一条正规方程为

$$\sum_{i=1}^{n} \hat{e}_i = \sum_{i=1}^{n} \big[y_i - (\hat{a} + \hat{b}x_i)\big] = 0,$$

故拟合残差的总和为零。 □

例题 1.5. 某地区三年的广告支出 x 与销售额 y 的观测数据为

$$(x_1, y_1) = (1, 2), \qquad (x_2, y_2) = (2, 3), \qquad (x_3, y_3) = (3, 5)。$$

这三个观测点的样本均值为

$$\bar{x} = \frac{1+2+3}{3} = 2, \qquad \bar{y} = \frac{2+3+5}{3} = \frac{10}{3}。$$

用一元直线拟合销售额与广告支出之间的线性关系。

解： 样本均值为

$$\bar{x} = 2, \qquad \bar{y} = \frac{10}{3}.$$

因此

$$\sum_{i=1}^{3} (x_i - \bar{x})(y_i - \bar{y}) = (-1)\left(-\frac{4}{3}\right) + 0\left(-\frac{1}{3}\right) + 1\left(\frac{5}{3}\right) = 3,$$

且

$$\sum_{i=1}^{3} (x_i - \bar{x})^2 = (-1)^2 + 0^2 + 1^2 = 2。$$

所以

$$\hat{b} = \frac{3}{2}, \qquad \hat{a} = \frac{10}{3} - \frac{3}{2} \cdot 2 = \frac{1}{3}。$$

拟合直线为

$$\hat{y} = \frac{1}{3} + \frac{3}{2}x。$$

三个观测点的拟合值和残差分别为

i	$\hat{y}_i$	$\hat{e}_i = y_i - \hat{y}_i$
1	$\frac{11}{6}$	$\frac{1}{6}$
2	$\frac{10}{3}$	$-\frac{1}{3}$
3	$\frac{29}{6}$	$\frac{1}{6}$

可见 $\hat{e}_1 + \hat{e}_2 + \hat{e}_3 = 0$，且拟合直线经过 $(\bar{x}, \bar{y}) = (2, 10/3)$。在经济解释上，该直线描述样本内广告支出与销售额的线性拟合关系，但不能仅凭拟合结果断言广告支出对销售额具有因果影响。

练习 1.6. 设三家企业的培训支出 x 与劳动生产率 y 的数据为

$$(x_1,y_1)=(1,4),\qquad (x_2,y_2)=(2,5),\qquad (x_3,y_3)=(4,8)。$$

完成下列任务：

1. 计算 $\bar{x}$ 和 $\bar{y}$；
2. 求最小二乘拟合直线 $\hat{y}=\hat{a}+\hat{b}x$；
3. 计算三个观测点的残差，并验证残差之和为零；
4. 求培训支出为 $x=3$ 时的拟合值，并说明这是样本区间内的插值。

练习答案

练习 1.6 的解答： 答案如下：

$$\bar{x}=\frac{1+2+4}{3}=\frac{7}{3},\qquad \bar{y}=\frac{4+5+8}{3}=\frac{17}{3}。$$

进一步有

$$\sum_{i=1}^{3}(x_i-\bar{x})(y_i-\bar{y})=\frac{19}{3},\qquad \sum_{i=1}^{3}(x_i-\bar{x})^2=\frac{14}{3}。$$

所以

$$\hat{b}=\frac{19/3}{14/3}=\frac{19}{14},\qquad \hat{a}=\frac{17}{3}-\frac{19}{14}\cdot\frac{7}{3}=\frac{5}{2}。$$

拟合直线为

$$\hat{y}=\frac{5}{2}+\frac{19}{14}x。$$

三个拟合值和残差为

i	$\hat{y}_i$	$\hat{e}_i=y_i-\hat{y}_i$
1	$\frac{27}{7}$	$\frac{1}{7}$
2	$\frac{73}{14}$	$-\frac{3}{14}$
3	$\frac{111}{14}$	$\frac{1}{14}$

残差之和为

$$\frac{1}{7}-\frac{3}{14}+\frac{1}{14}=0。$$

最后，$x=3$ 时的拟合值为

$$\hat{y}(3)=\frac{5}{2}+\frac{19}{14}\cdot 3=\frac{46}{7}。$$

由于 3 位于样本解释变量的最小值 1 与最大值 4 之间，这是样本区间内的插值。