最小二乘法讲义计划

1　一元最小二乘拟合：从平方误差到正规方程

定义 1.1. 设有 $n \geq 2$ 个观测点 (x_i, y_i)，其中 $x_i, y_i \in \mathbb{R}$，$i = 1, \ldots, n$。用直线

$$\hat{y}_i = a + bx_i$$

拟合被解释变量 y_i，其中 $a, b \in \mathbb{R}$ 分别为截距参数和斜率参数。定义平方误差目标函数为

$$S(a, b) = \sum_{i=1}^{n} \big[y_i - (a + bx_i)\big]^2. \tag{1}$$

一元最小二乘估计 $(\hat{a}, \hat{b})$ 是使 $S(a, b)$ 在 $\mathbb{R}^2$ 上达到最小值的参数对。

定义 1.2. 对给定的参数 a, b，第 i 个观测的残差定义为观测值与拟合值之差：

$$e_i = y_i - (a + bx_i). \tag{2}$$

当参数取最小二乘估计 $(\hat{a}, \hat{b})$ 时，记

$$\hat{y}_i = \hat{a} + \hat{b}x_i, \qquad \hat{e}_i = y_i - \hat{y}_i.$$

此时平方误差目标函数的最小值为残差平方和 $\sum_{i=1}^{n} \hat{e}_i^2$。

定理 1.3. 设 $x_i, y_i \in \mathbb{R}$，且

$$\sum_{i=1}^{n} (x_i - \bar{x})^2 > 0, \qquad \bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i, \qquad \bar{y} = \frac{1}{n}\sum_{i=1}^{n} y_i.$$

则平方误差函数 $S(a, b)$ 在 $\mathbb{R}^2$ 上具有唯一最小点 $(\hat{a}, \hat{b})$。该最小点满足正规方程

$$\sum_{i=1}^{n} \big[y_i - (\hat{a} + \hat{b}x_i)\big] = 0, \qquad \sum_{i=1}^{n} x_i \big[y_i - (\hat{a} + \hat{b}x_i)\big] = 0, \tag{3}$$

并且

$$\hat{b} = \frac{\sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n} (x_i - \bar{x})^2}, \qquad \hat{a} = \bar{y} - \hat{b}\bar{x}.$$

证明. 将 $S(a, b)$ 展开得

$$S(a, b) = \sum_{i=1}^{n} \big[y_i - a - bx_i\big]^2.$$

对 a 和 b 分别求偏导，得到

$$\frac{\partial S}{\partial a} = -2\sum_{i=1}^{n}\big[y_i - a - bx_i\big], \qquad \frac{\partial S}{\partial b} = -2\sum_{i=1}^{n} x_i\big[y_i - a - bx_i\big].$$

因此，最小点必须满足式 (3)。第一条正规方程给出

$$n\hat{a} + \hat{b}\sum_{i=1}^{n} x_i = \sum_{i=1}^{n} y_i,$$

从而

$$\hat{a} = \bar{y} - \hat{b}\bar{x}.$$

把它代入第二条正规方程，并利用

$$\sum_{i=1}^{n}(x_i - \bar{x}) = 0, \qquad \sum_{i=1}^{n}(y_i - \bar{y}) = 0,$$

可得

$$\hat{b}\sum_{i=1}^{n}(x_i - \bar{x})^2 = \sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}).$$

由于分母严格为正，故 $\hat{b}$ 唯一确定，随后 $\hat{a}$ 也唯一确定。

下面验证由上述公式给出的 $(\hat{a}, \hat{b})$ 确实满足正规方程。对第一条，有

$$\sum_{i=1}^{n}\big[y_i - (\hat{a} + \hat{b}x_i)\big] = \sum_{i=1}^{n} y_i - n\hat{a} - \hat{b}\sum_{i=1}^{n} x_i = n\bar{y} - n(\bar{y} - \hat{b}\bar{x}) - \hat{b}n\bar{x} = 0.$$

对第二条，利用 $\sum_{i=1}^{n}(x_i - \bar{x}) = 0$ 和 $\sum_{i=1}^{n}(y_i - \bar{y}) = 0$，有

$$\sum_{i=1}^{n} x_i\big[y_i - (\hat{a} + \hat{b}x_i)\big] = \sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}) - \hat{b}\sum_{i=1}^{n}(x_i - \bar{x})^2 = 0,$$

最后一步由 $\hat{b}$ 的定义得到。因此 $(\hat{a}, \hat{b})$ 满足式 (3)。

为说明这是唯一的全局最小点，令 $u = a - \hat{a}$，$v = b - \hat{b}$。由于 $(\hat{a}, \hat{b})$ 满足正规方程，直接展开平方项可得

$$S(a, b) = S(\hat{a}, \hat{b}) + \sum_{i=1}^{n}(u + vx_i)^2.$$

再将 $x_i = (x_i - \bar{x}) + \bar{x}$ 代入，并令 $w = u + v\bar{x}$，得到

$$\sum_{i=1}^{n}(u + vx_i)^2 = nw^2 + v^2\sum_{i=1}^{n}(x_i - \bar{x})^2 \geq 0.$$

当且仅当 $w = 0$ 且 $v = 0$ 时等号成立；由此 $u = 0$。所以 $(\hat{a}, \hat{b})$ 是唯一最小点。 □

定理 1.4. *在定理 (3) 的条件下，最小二乘拟合直线经过样本均值点 $(\bar{x}, \bar{y})$，即*

$$\hat{y}(\bar{x}) = \hat{a} + \hat{b}\bar{x} = \bar{y}.$$

等价地，含截距的一元最小二乘拟合满足

$$\sum_{i=1}^{n}\hat{e}_i = 0.$$

证明. 由定理 (3) 给出的截距公式，

$$\hat{a} = \bar{y} - \hat{b}\bar{x}.$$

因此

$$\hat{a} + \hat{b}\bar{x} = \bar{y}.$$

另一方面，第一条正规方程为

$$\sum_{i=1}^{n} \hat{e}_i = \sum_{i=1}^{n} \big[y_i - (\hat{a} + \hat{b}x_i)\big] = 0,$$

故拟合残差的总和为零。 □

例题 1.5. 某地区三年的广告支出 x 与销售额 y 的观测数据为

$$(x_1, y_1) = (1, 2), \qquad (x_2, y_2) = (2, 3), \qquad (x_3, y_3) = (3, 5)。$$

这三个观测点的样本均值为

$$\bar{x} = \frac{1+2+3}{3} = 2, \qquad \bar{y} = \frac{2+3+5}{3} = \frac{10}{3}。$$

用一元直线拟合销售额与广告支出之间的线性关系。

解： 样本均值为

$$\bar{x} = 2, \qquad \bar{y} = \frac{10}{3}.$$

因此

$$\sum_{i=1}^{3} (x_i - \bar{x})(y_i - \bar{y}) = (-1)\left(-\frac{4}{3}\right) + 0\left(-\frac{1}{3}\right) + 1\left(\frac{5}{3}\right) = 3,$$

且

$$\sum_{i=1}^{3} (x_i - \bar{x})^2 = (-1)^2 + 0^2 + 1^2 = 2。$$

所以

$$\hat{b} = \frac{3}{2}, \qquad \hat{a} = \frac{10}{3} - \frac{3}{2} \cdot 2 = \frac{1}{3}。$$

拟合直线为

$$\hat{y} = \frac{1}{3} + \frac{3}{2}x。$$

三个观测点的拟合值和残差分别为

i	$\hat{y}_i$	$\hat{e}_i = y_i - \hat{y}_i$
1	$\frac{11}{6}$	$\frac{1}{6}$
2	$\frac{10}{3}$	$-\frac{1}{3}$
3	$\frac{29}{6}$	$\frac{1}{6}$

可见 $\hat{e}_1 + \hat{e}_2 + \hat{e}_3 = 0$，且拟合直线经过 $(\bar{x}, \bar{y}) = (2, 10/3)$。在经济解释上，该直线描述样本内广告支出与销售额的线性拟合关系，但不能仅凭拟合结果断言广告支出对销售额具有因果影响。

练习 1.6. 设三家企业的培训支出 x 与劳动生产率 y 的数据为

$$(x_1, y_1) = (1, 4), \qquad (x_2, y_2) = (2, 5), \qquad (x_3, y_3) = (4, 8)。$$

完成下列任务：

1. 计算 $\bar{x}$ 和 $\bar{y}$；
2. 求最小二乘拟合直线 $\hat{y} = \hat{a} + \hat{b}x$；
3. 计算三个观测点的残差，并验证残差之和为零；
4. 求培训支出为 $x = 3$ 时的拟合值，并说明这是样本区间内的插值。

2 多元最小二乘与矩阵表示

定义 2.1. 设有 $n \geq 1$ 个观测，每个观测包含一个被解释变量 $y_i \in \mathbb{R}$ 和 $p-1$ 个解释变量 $x_{i1}, \ldots, x_{i,p-1} \in \mathbb{R}$。设计矩阵 $X \in \mathbb{R}^{n \times p}$ 定义如下：当 $p \geq 2$ 时，

$$X = \begin{bmatrix} 1 & x_{11} & \cdots & x_{1,p-1} \\ 1 & x_{21} & \cdots & x_{2,p-1} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \cdots & x_{n,p-1} \end{bmatrix};$$

当 $p = 1$ 时，模型仅含截距项，$X = \begin{bmatrix} 1 & \cdots & 1 \end{bmatrix}^{\mathsf{T}} \in \mathbb{R}^{n \times 1}$。在后一情形中，约定空和 $\sum_{j=1}^{0}(\cdot) = 0$。第一列的 1 表示模型含有截距项。令参数列向量、响应列向量分别为

$$\beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_{p-1} \end{bmatrix} \in \mathbb{R}^p, \qquad y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} \in \mathbb{R}^n.$$

矩阵形式的线性拟合值为 $X\beta$，第 i 个拟合值为 $\beta_0 + \sum_{j=1}^{p-1} \beta_j x_{ij}$；特别地，当 $p = 1$ 时，该式按上述空和约定退化为 β_0。

定义 2.2. 对任意参数向量 $\beta \in \mathbb{R}^p$，残差向量定义为

$$e(\beta) = y - X\beta. \tag{4}$$

其第 i 个分量为

$$e_i(\beta) = y_i - \left(\beta_0 + \sum_{j=1}^{p-1} \beta_j x_{ij} \right).$$

矩阵形式的平方误差目标函数定义为

$$Q(\beta) = e(\beta)^{\mathsf{T}} e(\beta) = (y - X\beta)^{\mathsf{T}} (y - X\beta) = \sum_{i=1}^{n} e_i(\beta)^2.$$

当 $p = 2$ 且 X 的第二列为 $(x_1, \ldots, x_n)^{\mathsf{T}}$ 时，$Q(\beta)$ 就是前文的一元目标函数 $S(a, b)$，其中 $\beta = (a, b)^{\mathsf{T}}$。

定义 2.3. 若设计矩阵 $X \in \mathbb{R}^{n\times p}$ 的列向量线性无关，则称 X 列满秩，即 $\operatorname{rank}(X) = p$。这要求 $p \le n$，并且不存在非零向量 $v \in \mathbb{R}^p$ 使得 $Xv = 0$。在列满秩条件下，矩阵 $X^{\mathsf{T}}X \in \mathbb{R}^{p\times p}$ 可逆。

定理 2.4. 设 $X \in \mathbb{R}^{n\times p}$, $y \in \mathbb{R}^n$, 且 X 列满秩, 即 $\operatorname{rank}(X) = p$。定义 $Q(\beta) = (y-X\beta)^{\mathsf{T}}(y-X\beta)$。则 Q 在 $\mathbb{R}^p$ 上存在唯一最小点 $\hat{\beta}$，并且该最小点满足矩阵正规方程

$$X^{\mathsf{T}}X\hat{\beta} = X^{\mathsf{T}}y. \tag{5}$$

由于 $X^{\mathsf{T}}X$ 可逆，唯一最小二乘解为

$$\hat{\beta} = (X^{\mathsf{T}}X)^{-1}X^{\mathsf{T}}y.$$

对应的拟合值和残差分别为 $\hat{y} = X\hat{\beta}$ 与 $\hat{e} = y - X\hat{\beta}$。

证明. 将目标函数展开为

$$Q(\beta) = y^{\mathsf{T}}y - 2\beta^{\mathsf{T}}X^{\mathsf{T}}y + \beta^{\mathsf{T}}X^{\mathsf{T}}X\beta.$$

对 β 的各个分量求偏导，得到梯度

$$\nabla Q(\beta) = -2X^{\mathsf{T}}y + 2X^{\mathsf{T}}X\beta.$$

因此，最小点必须满足 $\nabla Q(\hat{\beta}) = 0$，也就是

$$X^{\mathsf{T}}X\hat{\beta} = X^{\mathsf{T}}y,$$

这就是式 (5)。

由于 X 列满秩，对任意非零向量 $v \in \mathbb{R}^p$，都有 $Xv \neq 0$，从而

$$v^{\mathsf{T}}X^{\mathsf{T}}Xv = (Xv)^{\mathsf{T}}(Xv) = \sum_{i=1}^{n}(Xv)_i^2 > 0.$$

所以 $X^{\mathsf{T}}X$ 可逆，正规方程至多有一个解，并且该解为

$$\hat{\beta} = (X^{\mathsf{T}}X)^{-1}X^{\mathsf{T}}y.$$

还需说明该解确实给出全局最小值。令 $h = \beta - \hat{\beta}$，则 $\beta = \hat{\beta} + h$，并且

$$y - X\beta = (y - X\hat{\beta}) - Xh.$$

展开平方误差可得

$$Q(\beta) = Q(\hat{\beta}) - 2h^{\mathsf{T}}X^{\mathsf{T}}(y - X\hat{\beta}) + h^{\mathsf{T}}X^{\mathsf{T}}Xh.$$

由正规方程，$X^{\mathsf{T}}(y - X\hat{\beta}) = 0$，因此

$$Q(\beta) = Q(\hat{\beta}) + h^{\mathsf{T}}X^{\mathsf{T}}Xh = Q(\hat{\beta}) + (Xh)^{\mathsf{T}}(Xh) \ge Q(\hat{\beta}).$$

当且仅当 $Xh = 0$ 时等号成立。列满秩又保证 $Xh = 0$ 只能推出 $h = 0$，即 $\beta = \hat{\beta}$。所以 $\hat{\beta}$ 是唯一的全局最小点。 □

定理 2.5. 在定理 (5) 的条件下，最小二乘残差 $\hat{e} = y - X\hat{\beta}$ 满足

$$X^{\mathsf{T}}\hat{e} = 0.$$

也就是说，残差向量与设计矩阵的每一列都正交。特别地，当模型含截距项时，X 的第一列为全 1 向量，于是

$$\sum_{i=1}^{n} \hat{e}_i = 0.$$

当模型还包含解释变量列 $(x_{1j}, \dots, x_{nj})^{\mathsf{T}}$ 时，还满足

$$\sum_{i=1}^{n} x_{ij}\hat{e}_i = 0, \qquad j = 1, \dots, p-1.$$

证明. 由定理 (5) 的正规方程，

$$X^{\mathsf{T}}X\hat{\beta} = X^{\mathsf{T}}y.$$

移项得到

$$X^{\mathsf{T}}(y - X\hat{\beta}) = 0.$$

根据残差向量的定义 (4)，这就是

$$X^{\mathsf{T}}\hat{e} = 0.$$

矩阵乘积的第 j 个分量等于设计矩阵第 j 列与残差向量的内积，因此每一列都与残差向量正交。若第一列为全 1 向量，则对应内积为 $\sum_{i=1}^{n} \hat{e}_i$；若第 $j+1$ 列为解释变量 x_j，则对应内积为 $\sum_{i=1}^{n} x_{ij}\hat{e}_i$。□

例题 2.6. 某企业有三次观测，y 表示劳动生产率，x_1 表示培训支出，x_2 表示设备投入。观测数据为

i	x_{i1}	x_{i2}	y_i
1	1	0	4
2	0	1	3
3	1	1	5

考虑含截距的模型

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + e_i.$$

写出设计矩阵 X、响应向量 y，并利用矩阵正规方程求最小二乘估计。

解： 由数据可得

$$X = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 1 & 1 \end{bmatrix}, \qquad y = \begin{bmatrix} 4 \\ 3 \\ 5 \end{bmatrix}.$$

计算得到

$$X^{\mathsf{T}}X = \begin{bmatrix} 3 & 2 & 2 \\ 2 & 2 & 1 \\ 2 & 1 & 2 \end{bmatrix}, \qquad X^{\mathsf{T}}y = \begin{bmatrix} 12 \\ 9 \\ 8 \end{bmatrix}.$$

因此正规方程为

$$\begin{bmatrix} 3 & 2 & 2 \\ 2 & 2 & 1 \\ 2 & 1 & 2 \end{bmatrix} \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \end{bmatrix} = \begin{bmatrix} 12 \\ 9 \\ 8 \end{bmatrix}.$$

直接检验可得

$$\hat{\beta} = \begin{bmatrix} 2 \\ 2 \\ 1 \end{bmatrix},$$

因为

$$\begin{bmatrix} 3 & 2 & 2 \\ 2 & 2 & 1 \\ 2 & 1 & 2 \end{bmatrix} \begin{bmatrix} 2 \\ 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 12 \\ 9 \\ 8 \end{bmatrix}.$$

所以拟合方程为

$$\hat{y} = 2 + 2x_1 + x_2.$$

三个观测的拟合值依次为 $4, 3, 5$，因此残差向量为

$$\hat{e} = y - X\hat{\beta} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}.$$

在这个例子中，三个观测点恰好被模型完全拟合。若给定一个新的解释变量取值 $(x_1, x_2) = (2, 1)$，则将其代入拟合方程可得样本外预测值

$$\widehat{y}(2, 1) = 2 + 2 \times 2 + 1 = 7.$$

由于样本中 x_1 只取过 0 和 1，这里的预测涉及超出样本观测范围的外推，应谨慎解释其可靠性。这个计算说明矩阵正规方程可以同时处理多个解释变量，但拟合关系仍然只是样本内的线性拟合，不能据此断言培训支出或设备投入对劳动生产率具有因果影响。

练习 2.7. 设三次观测的设计矩阵和响应向量为

$$X = \begin{bmatrix} 1 & 0 & 1 \\ 1 & 1 & 0 \\ 1 & 1 & 1 \end{bmatrix}, \qquad y = \begin{bmatrix} 2 \\ 4 \\ 5 \end{bmatrix}.$$

完成下列任务：

1. 计算 $X^{\mathsf{T}}X$ 和 $X^{\mathsf{T}}y$；
2. 利用正规方程求 $\hat{\beta} = (\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2)^{\mathsf{T}}$；
3. 写出拟合方程 $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2$；
4. 计算残差向量，并验证它与 X 的每一列正交。

练习答案

练习 1.6 的解答： 答案如下：

$$\bar{x} = \frac{1+2+4}{3} = \frac{7}{3}, \qquad \bar{y} = \frac{4+5+8}{3} = \frac{17}{3}。$$

进一步有

$$\sum_{i=1}^{3}(x_i - \bar{x})(y_i - \bar{y}) = \frac{19}{3}, \qquad \sum_{i=1}^{3}(x_i - \bar{x})^2 = \frac{14}{3}。$$

所以

$$\hat{b} = \frac{19/3}{14/3} = \frac{19}{14}, \qquad \hat{a} = \frac{17}{3} - \frac{19}{14}\cdot\frac{7}{3} = \frac{5}{2}。$$

拟合直线为

$$\hat{y} = \frac{5}{2} + \frac{19}{14}x。$$

三个拟合值和残差为

i	$\hat{y}_i$	$\hat{e}_i = y_i - \hat{y}_i$
1	$\frac{27}{7}$	$\frac{1}{7}$
2	$\frac{73}{14}$	$-\frac{3}{14}$
3	$\frac{111}{14}$	$\frac{1}{14}$

残差之和为

$$\frac{1}{7} - \frac{3}{14} + \frac{1}{14} = 0。$$

最后，$x = 3$ 时的拟合值为

$$\hat{y}(3) = \frac{5}{2} + \frac{19}{14}\cdot 3 = \frac{46}{7}。$$

由于 3 位于样本解释变量的最小值 1 与最大值 4 之间，这是样本区间内的插值。

练习 2.7 的解答： 先计算矩阵乘积：

$$X^{\mathsf{T}}X = \begin{bmatrix} 3 & 2 & 2 \\ 2 & 2 & 1 \\ 2 & 1 & 2 \end{bmatrix}, \qquad X^{\mathsf{T}}y = \begin{bmatrix} 11 \\ 9 \\ 7 \end{bmatrix}.$$

正规方程为

$$\begin{bmatrix} 3 & 2 & 2 \\ 2 & 2 & 1 \\ 2 & 1 & 2 \end{bmatrix} \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \end{bmatrix} = \begin{bmatrix} 11 \\ 9 \\ 7 \end{bmatrix}.$$

解得

$$\hat{\beta} = \begin{bmatrix} 1 \\ 3 \\ 1 \end{bmatrix}.$$

因此拟合方程为

$$\hat{y} = 1 + 3x_1 + x_2.$$

拟合值为

$$X\hat{\beta} = \begin{bmatrix} 2 \\ 4 \\ 5 \end{bmatrix} = y,$$

故残差向量为

$$\hat{e} = y - X\hat{\beta} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}.$$

于是

$$X^{\mathsf{T}}\hat{e} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix},$$

这验证了残差向量与设计矩阵的每一列正交。