目录

1. 误差如何度量：从残差到常数拟合
2. 直线最小二乘：消去截距并求解正规方程
3. 结果检验、退化情形与工程解释

误差如何度量：从残差到常数拟合

对同一个量重复测量时，读数往往并不完全相同。如果要用一个数代表这些读数，应当如何选择？最小二乘法先规定误差的度量，再寻找使这种误差最小的模型参数。本节从常数拟合入手，只使用有限求和、一元求导和配方法。

定义

设 $n \geq 1$ 为整数，$y_i \in \mathbb{R}$ 是第 i 次观测的响应值，$i = 1, \ldots, n$。若记录中还有自变量，则用 $x_i \in \mathbb{R}$ 表示第 i 次观测的输入。给定模型及其参数后，模型对第 i 次观测给出的数值记为 $\hat{y}_i$，称为拟合值。

约定残差为观测值减去拟合值：

$$r_i = y_i - \hat{y}_i, \qquad i = 1, \ldots, n.$$

因此，$r_i > 0$ 表示模型低估了该观测值，$r_i < 0$ 表示模型高估了该观测值。残差平方和定义为

$$Q = \sum_{i=1}^{n} r_i^2 = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2.$$

误差如何度量：从残差到常数拟合

为什么不直接用残差之和度量拟合误差？正负残差可能互相抵消。例如，两个残差为 1 与 -1 时，残差之和为零，但两个拟合值都没有命中观测值。平方后各项非负，不能发生这种抵消；并且

$$\sum_{i=1}^{n} r_i^2 = 0 \quad \Longleftrightarrow \quad r_i = 0 \text{ 对所有} i = 1, \ldots, n.$$

平方也会使较大的残差更显著地影响目标函数。如果响应值有计量单位，残差与响应值同单位，而残差平方和具有该单位的平方。比较不同候选模型的平方和时，本节始终使用同一组数据和相同单位。

定义

设 $n \geq 1$ 为整数，观测值为 $y_1, \ldots, y_n \in \mathbb{R}$。常数模型用同一个待定实数 c 拟合所有观测值，即

$$\hat{y}_i = c, \qquad i = 1, \ldots, n, \qquad c \in \mathbb{R}.$$

相应的目标函数是

$$Q(c) = \sum^{n} (y_i - c)^2, \qquad c \in \mathbb{R}.$$

误差如何度量：从残差到常数拟合

定理

设 $n \geq 1$ 为整数，$y_1, \ldots, y_n \in \mathbb{R}$，并令 $\bar{y} = \frac{1}{n}\sum_{i=1}^{n} y_i$。则常数模型的残差平方和满足：对每个 $c \in \mathbb{R}$，

$$Q(c) = \sum_{i=1}^{n} (y_i - \bar{y})^2 + n(c - \bar{y})^2.$$

因此，$Q(c)$ 在且仅在 $c = \bar{y}$ 时取得全局最小值，最小值为

$$Q(\bar{y}) = \sum_{i=1}^{n} (y_i - \bar{y})^2.$$

误差如何度量：从残差到常数拟合

定理

设 $n \geq 1$ 为整数，$y_1, \ldots, y_n \in \mathbb{R}$，并令 $\bar{y} = \frac{1}{n}\sum_{i=1}^{n} y_i$。则常数模型的残差平方和满足：对每个 $c \in \mathbb{R}$，

$$Q(c) = \sum_{i=1}^{n} (y_i - \bar{y})^2 + n(c - \bar{y})^2.$$

因此，$Q(c)$ 在且仅在 $c = \bar{y}$ 时取得全局最小值，最小值为

$$Q(\bar{y}) = \sum_{i=1}^{n} (y_i - \bar{y})^2.$$

证明：先用一元求导寻找候选参数。对任意 $c \in \mathbb{R}$，有限项逐项求导得

$$Q'(c) = 2\sum_{i=1}^{n} (c - y_i) = 2n(c - \bar{y}).$$

误差如何度量：从残差到常数拟合

例题

某个保持不变的量经过三次测量，读数依次为 $2, 3, 7$，单位相同。用常数模型拟合这些读数：写出目标函数，求最优常数及最小残差平方和，并与候选常数 $c = 3$ 比较。

误差如何度量：从残差到常数拟合

解：对 $c \in \mathbb{R}$，目标函数为

$$\begin{aligned} Q(c) &= (2-c)^2 + (3-c)^2 + (7-c)^2 \\ &= 3c^2 - 24c + 62 \\ &= 3(c-4)^2 + 14. \end{aligned}$$

三个读数的平均数是 $\bar{y} = (2+3+7)/3 = 4$，所以唯一最优常数为 $c = 4$。这也可从 $Q'(c) = 6c - 24$ 和上述配方看出。
将两个候选常数的残差列在一起：

候选常数	r_1	r_2	r_3	$Q(c)$
$c = 3$	-1	0	4	17
$c = 4$	-2	-1	3	14

因此最小平方和为 $Q(4) = 4 + 1 + 9 = 14$，而 $Q(3) = 1 + 0 + 16 = 17$。从 $c = 3$ 改为 $c = 4$ 后，前两个残差的绝对值反而增大，但总平方和减小了 3。这说明最小二乘法优化的是整体指标，并不要求每次测量的拟合误差都同时减小。
常数拟合给出了一个可重复使用的思路：先明确参数与目标函数，再求导寻找候选点，最后用二次项分解最小二乘最优性，标签式 $Q(c) = Q(\bar{y}) + (c-\bar{y})^2$ 证实最小即已使离差最优参数

误差如何度量：从残差到常数拟合

练习

对同单位的四次测量值 $1, 2, 4, 5$ 作常数拟合。写出 $Q(c)$ 的平方和形式，求最优常数、各个残差及最小平方和；再计算 $Q(2)$，并用平方和分解解释它与最小值之差。本题答案统一置于讲义末尾。

误差如何度量：从残差到常数拟合

练习

设 $n \geq 1$ 为整数，$y_1, \ldots, y_n \in \mathbb{R}$，常数模型的残差为 $r_i = y_i - c$，其中 $c \in \mathbb{R}$。判断并说明理由：

(1) 若 $\sum_{i=1}^{n} r_i = 0$，则 c 是该常数模型的唯一最优参数。

(2) 若 $\sum_{i=1}^{n} r_i = 0$，则每一个残差都等于零。

(3) 当 $n = 1$ 时，常数模型仍有唯一最优参数。

本题答案统一置于讲义末尾。

目录

1. 误差如何度量：从残差到常数拟合
2. 直线最小二乘：消去截距并求解正规方程
3. 结果检验、退化情形与工程解释

直线最小二乘：消去截距并求解正规方程

第2节 用一个常数代表一组观测值。本节允许拟合值随输入作线性变化，用直线描述数据的整体趋势。虽然有截距和斜率两个参数，我们仍只用一元微积分：先固定斜率求最佳截距，再求最佳斜率，最后用配方证明全局最优性。

定义

设 $n \geq 1$ 为整数，给定数据点 $(x_i, y_i) \in \mathbb{R}^2$，$i = 1, \ldots, n$。带截距的直线拟合模型为

$$\hat{y}_i = a + b x_i, \qquad a, b \in \mathbb{R},$$

其中 a 是截距，b 是斜率。残差与目标函数分别为

$$r_i = y_i - a - b x_i, \qquad Q(a, b) = \sum_{i=1}^{n} (y_i - a - b x_i)^2.$$

最小二乘直线指使 $Q(a, b)$ 在所有实参数对 (a, b) 中取得最小值的直线。这里截距也是待定参数，并未要求直线经过原点。

直线最小二乘：消去截距并求解正规方程

定义

对上述数据，定义均值

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i, \qquad \bar{y} = \frac{1}{n}\sum_{i=1}^{n} y_i.$$

中心化数据是 $x_i - \bar{x}$ 与 $y_i - \bar{y}$，其各自的和均为零。定义

$$S_{xx} = \sum_{i=1}^{n} (x_i - \bar{x})^2, \qquad S_{xy} = \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y}).$$

平方展开并利用均值定义，可得便于手算的形式

$$S_{xx} = \sum_{i=1}^{n} x_i^2 - n\bar{x}^2, \qquad S_{xy} = \sum_{i=1}^{n} x_i y_i - n\bar{x}\bar{y}.$$

这些量都只由观测数据决定，与待定参数 a, b 无关。

直线最小二乘：消去截距并求解正规方程

固定任意 $b \in \mathbb{R}$，把 $y_i - bx_i$ 看作新的观测值。它们的平均数是 $\bar{y} - b\bar{x}$。由第2节的常数拟合结论，此时唯一最优截距是

$$a = \bar{y} - b\bar{x}.$$

更具体地，对所有 $a, b \in \mathbb{R}$，有分解

$$Q(a, b) = F(b) + n(a + b\bar{x} - \bar{y})^2,$$

其中

$$\begin{aligned} F(b) &= Q(\bar{y} - b\bar{x}, b) \\ &= \sum_{i=1}^{n} \big((y_i - \bar{y}) - b(x_i - \bar{x})\big)^2 \\ &= \sum_{i=1}^{n} (y_i - \bar{y})^2 - 2bS_{xy} + b^2 S_{xx}. \end{aligned}$$

因此，先把截距选为对应斜率下的最优值，再最小化一元函数 F，不会漏掉更好的参数对。若 $S_{xx} > 0$，则

$$F'(b) = 2S_{xx}b - 2S_{xy}.$$

直线最小二乘：消去截距并求解正规方程

定理

设 $n \geq 1$ 为整数，$(x_i, y_i) \in \mathbb{R}^2$，$i = 1, \ldots, n$。条件 $S_{xx} > 0$ 等价于 $x_1, \ldots, x_n$ 不全相同。在此条件下，$Q(a, b)$ 在 $\mathbb{R}^2$ 上有唯一全局最小点

$$b_* = \frac{S_{xy}}{S_{xx}}, \qquad a_* = \bar{y} - b_* \bar{x}.$$

参数对 (a_*, b_*) 也是正规方程的唯一解。对任意 $a, b \in \mathbb{R}$，有

$$Q(a, b) = Q(a_*, b_*) + S_{xx}(b - b_*)^2 + n(a + b\bar{x} - \bar{y})^2,$$

其中

$$Q(a_*, b_*) = \sum_{i=1}^{n} (y_i - \bar{y})^2 - \frac{S_{xy}^2}{S_{xx}}.$$

直线最小二乘：消去截距并求解正规方程

定理

设 $n \geq 1$ 为整数，$(x_i, y_i) \in \mathbb{R}^2$，$i = 1, \ldots, n$。条件 $S_{xx} > 0$ 等价于 $x_1, \ldots, x_n$ 不全相同。在此条件下，$Q(a, b)$ 在 $\mathbb{R}^2$ 上有唯一全局最小点

$$b_* = \frac{S_{xy}}{S_{xx}}, \qquad a_* = \bar{y} - b_* \bar{x}.$$

参数对 (a_*, b_*) 也是正规方程的唯一解。对任意 $a, b \in \mathbb{R}$，有

$$Q(a, b) = Q(a_*, b_*) + S_{xx}(b - b_*)^2 + n(a + b\bar{x} - \bar{y})^2,$$

其中

$$Q(a_*, b_*) = \sum_{i=1}^{n} (y_i - \bar{y})^2 - \frac{S_{xy}^2}{S_{xx}}.$$

证明：由于 S_{xx} 是非负项之和，$S_{xx} = 0$ 当且仅当每个 $x_i - \bar{x} = 0$，也就是所有 x_i 相同。因此

直线最小二乘：消去截距并求解正规方程

例题

对数据点 $(0,1)$、$(1,2)$、$(2,2)$ 求带截距的最小二乘直线。列出均值、中心化求和、最优参数、各个残差及最小残差平方和，并核对两条正规方程。

直线最小二乘：消去截距并求解正规方程

解：均值为

$$\bar{x} = \frac{0+1+2}{3} = 1, \qquad \bar{y} = \frac{1+2+2}{3} = \frac{5}{3}.$$

中心化计算如下：

i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})^2$	$(x_i - \bar{x})(y_i - \bar{y})$
1	-1	$-2/3$	1	$2/3$
2	0	$1/3$	0	0
3	1	$1/3$	1	$1/3$

因此 $S_{xx} = 2 > 0$、$S_{xy} = 1$，**唯一最优参数为**

$$b_* = \frac{1}{2}, \qquad a_* = \frac{5}{3} - \frac{1}{2} = \frac{7}{6}.$$

最小二乘直线是 $\hat{y} = \frac{7}{6} + \frac{1}{2}x$。**逐点计算拟合值和残差**：

i	x_i	y_i	$\hat{y}_i$	r_i
1	0	1	$7/6$	$-1/6$
2	1	2	$5/3$	$1/3$
3	2	2	$13/6$	$1/6$

直线最小二乘：消去截距并求解正规方程

练习

对数据点 $(0,1)$、$(1,1)$、$(2,3)$ 求带截距的最小二乘直线。计算 $\bar{x}, \bar{y}, S_{xx}, S_{xy}$，列出残差及最小平方和，并核对正规方程。答案统一置于讲义末尾。

直线最小二乘：消去截距并求解正规方程

练习

设 $n \geq 2$ 为整数，给定实数据点 (x_i, y_i)，$i = 1, \ldots, n$，且 $S_{xx} > 0$。判断下列说法并说明理由。

(1) 若 $S_{xy} = 0$，则所有 y_i 必须相同。

(2) 任意满足 $\sum_{i=1}^{n}(y_i - a - bx_i) = 0$ 的实参数对 (a, b)，都是最小二乘解。

(3) 若某实参数对同时满足两条正规方程，则它是唯一最小二乘解。

答案统一置于讲义末尾。

目录

1. 误差如何度量：从残差到常数拟合
2. 直线最小二乘：消去截距并求解正规方程
3. 结果检验、退化情形与工程解释

结果检验、退化情形与工程解释

第10节给出了带截距直线的求解方法。本节进一步回答三个问题：怎样利用残差检验计算结果？当自变量观测值全相同时还能确定什么？把拟合直线用于工程预测时，哪些结论不能仅由平方和最小推出？以下仍只使用有限求和、二元一次方程和配方法。

定义

设 $n \geq 1$ 为整数，观测数据为 $(x_i, y_i) \in \mathbb{R}^2$，$i = 1, \ldots, n$。选定拟合函数 f 后，令 $\hat{y}_i = f(x_i)$、$r_i = y_i - \hat{y}_i$。残差表是按观测编号列出 $x_i, y_i, \hat{y}_i, r_i$ 的表格，也可以增加 r_i^2 一列，以便求出残差平方和。

插值要求函数在每个观测位置都准确命中观测值，即 $f(x_i) = y_i$ 对所有 i 成立。拟合则是在指定函数模型内按某种整体准则选择参数，不要求逐点命中。本讲义采用的准则是最小化 $\sum_{i=1}^{n} r_i^2$。若同一个输入对应不同的观测输出，就不存在同时命中这些记录的单值插值函数；最小二乘拟合仍有意义。

记 $x_{\min} = \min\{x_1, \ldots, x_n\}$、$x_{\max} = \max\{x_1, \ldots, x_n\}$。将拟合模型用于输入 $x_0 \in [x_{\min}, x_{\max}]$ 的输出估计，称为区间内预测；用于 $x_0 < x_{\min}$ 或 $x_0 > x_{\max}$ 的估计，称为外推。区间内预测并不等于要求逐点命中的插值。

预测所用的 $\hat{y}(x_0) = f(x_0)$ 是模型计算值。即使 x_0 位于已有观测位置，它也不一定等于该处已有的观测值，更不能保证等于以后在同一输入下测得的实际输出。

结果检验、退化情形与工程解释

定理

设 $n \geq 1$ 为整数，$(x_i, y_i) \in \mathbb{R}^2$，$i = 1, \ldots, n$，且 $\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$、$\bar{y} = \frac{1}{n}\sum_{i=1}^{n} y_i$。若 (a_*, b_*) 是目标函数

$$Q(a, b) = \sum_{i=1}^{n} (y_i - a - bx_i)^2, \qquad (a, b) \in \mathbb{R}^2,$$

的一个全局最小点，则其残差 $r_i = y_i - a_* - b_* x_i$ 满足

$$\sum_{i=1}^{n} r_i = 0, \qquad a_* + b_* \bar{x} = \bar{y}.$$

因此最小二乘直线经过数据均值点 $(\bar{x}, \bar{y})$。这些结论不要求 $S_{xx} > 0$，但要求这里的模型包含可自由选择的截距，且使用上述未加权的残差平方和。

结果检验、退化情形与工程解释

定理

设 $n \geq 1$ 为整数，$(x_i, y_i) \in \mathbb{R}^2$，$i = 1, \ldots, n$，且 $\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$、$\bar{y} = \frac{1}{n}\sum_{i=1}^{n} y_i$。若 (a_*, b_*) 是目标函数

$$Q(a, b) = \sum_{i=1}^{n} (y_i - a - bx_i)^2, \qquad (a, b) \in \mathbb{R}^2,$$

的一个全局最小点，则其残差 $r_i = y_i - a_* - b_* x_i$ 满足

$$\sum_{i=1}^{n} r_i = 0, \qquad a_* + b_* \bar{x} = \bar{y}.$$

因此最小二乘直线经过数据均值点 $(\bar{x}, \bar{y})$。这些结论不要求 $S_{xx} > 0$，但要求这里的模型包含可自由选择的截距，且使用上述未加权的残差平方和。

证明：固定最优参数中的斜率 b_*。由第2节的常数拟合结论，数据 $y_i - b_* x_i$ 的唯一最优常数是其平均数 $\bar{y} - b_* \bar{x}$。如果 a_* 不等于这个数，仅改变截距就会严格减小平方和，与全局最优性矛盾。因此

结果检验、退化情形与工程解释

残差和为零与通过均值点实际上是同一个等式的两种表达，不能把它们当作两项独立的最优性条件。残差和为零也不表示每个残差都为零。若 $S_{xx} > 0$，还可以检验第二条正规方程，即 $\sum_{i=1}^{n} x_i r_i = 0$；由第10节的结论，同时满足两条正规方程的参数对才是唯一最小二乘解。这些代数条件用于检验是否求对了指定模型的最优参数，并不证明模型适合工程对象。若按输入从小到大观察残差，发现它们呈现有规律的变化，可将其作为重新考虑直线模型的线索；但少量残差本身不足以确定变化原因。

截距的前提不能省略。例如，仅允许过原点的模型 $\hat{y} = bx$ 时，对数据 $(0,1)$、$(1,1)$ 有

$$Q(b) = 1 + (1-b)^2, \qquad b \in \mathbb{R}.$$

唯一最优斜率为 $b = 1$，残差为 $1, 0$，其和不为零；直线 $\hat{y} = x$ 也不经过数据均值点 $(1/2, 1)$。

例题

把第10节的数据 $(0,1)$、$(1,2)$、$(2,2)$ 看成某传感器的三组输入输出记录，输入和输出均按各自固定单位记数。已求得最小二乘直线 $\hat{y} = 7/6 + x/2$。列出残差表，核验残差和与均值点性质；估计输入 1.5 时的输出，并讨论把模型用于输入 10 时的局限。

结果检验、退化情形与工程解释

解：对实数输入 x，拟合模型为 $\hat{y}(x) = 7/6 + x/2$。在已有观测处，残差表为

i	x_i	y_i	$\hat{y}_i$	r_i	r_i^2
1	0	1	$7/6$	$-1/6$	$1/36$
2	1	2	$5/3$	$1/3$	$1/9$
3	2	2	$13/6$	$-1/6$	$1/36$

因此

$$\sum_{i=1}^{3} r_i = -\frac{1}{6} + \frac{1}{3} - \frac{1}{6} = 0, \qquad Q(a_*, b_*) = \frac{1}{6}.$$

负残差表示模型高估了该次观测输出，正残差表示模型低估了该次观测输出。这里模型没有命中任何一个观测点，却仍使总平方和最小。

均值点为 $(\bar{x}, \bar{y}) = (1, 5/3)$，且

$$\hat{y}(1) = \frac{7}{6} + \frac{1}{2} = \frac{5}{3} = \bar{y}.$$

第二条残差关系也成立：$\sum_{i=1}^{3} x_i r_i = 0 + 1/3 - 2/6 = 0$。

输入 1.5 与 2（最小二乘法）输入区间 $[0, 2]$ 中，模型给出的区间内预测为

结果检验、退化情形与工程解释

解：对实数输入 x，拟合模型为 $\hat{y}(x) = 7/6 + x/2$。在已有观测处，残差表为

i	x_i	y_i	$\hat{y}_i$	r_i	r_i^2
1	0	1	$7/6$	$-1/6$	$1/36$
2	1	2	$5/3$	$1/3$	$1/9$
3	2	2	$13/6$	$-1/6$	$1/36$

因此

$$\sum_{i=1}^{3} r_i = -\frac{1}{6} + \frac{1}{3} - \frac{1}{6} = 0, \qquad Q(a_*, b_*) = \frac{1}{6}.$$

负残差表示模型高估了该次观测输出，正残差表示模型低估了该次观测输出。这里模型没有命中任何一个观测点，却仍使总平方和最小。

均值点为 $(\bar{x}, \bar{y}) = (1, 5/3)$，且

$$\hat{y}(1) = \frac{7}{6} + \frac{1}{2} = \frac{5}{3} = \bar{y}.$$

第二条残差关系也成立：$\sum_{i=1}^{3} x_i r_i = 0 + 1/3 - 2/6 = 0$。

输入 1.5 与 2（最小二乘法）输入区间 $[0, 2]$ 中，模型给出的区间内预测为

结果检验、退化情形与工程解释

例题

对数据点 $(2,1)$、$(2,3)$、$(2,5)$ 作带截距的直线最小二乘拟合。求全部最优参数对、残差和最小平方和。能否唯一确定输入 2 与输入 3 时的拟合输出？

结果检验、退化情形与工程解释

解：三个自变量观测值均为 2，所以 $\bar{x}=2$、$S_{xx}=0$，不能使用 $b_*=S_{xy}/S_{xx}$ 的除法公式。响应平均数为 $\bar{y}=(1+3+5)/3=3$。对所有 $a,b\in\mathbb{R}$，

$$\begin{aligned} Q(a,b) &= (1-a-2b)^2+(3-a-2b)^2+(5-a-2b)^2 \\ &= 8+3(a+2b-3)^2. \end{aligned}$$

因此全部最优参数满足

$$a+2b=3, \quad \text{即} \quad (a,b)=(3-2b,b), \qquad b\in\mathbb{R}.$$

每组最优参数在输入 2 处都给出拟合值 3，对应残差依次为 $-2,0,2$，最小平方和为 $4+0+4=8$。

例如 $\hat{y}=3$ 与 $\hat{y}=1+x$ 都是最优直线。它们在输入 3 处分别给出 3 与 4。一般地，最优直线在实数输入 x 处的值为

$$\hat{y}(x)=3+b(x-2), \qquad b\in\mathbb{R}.$$

所以输入 2 时的拟合输出唯一，输入 3 时的拟合输出却随斜率改变。本例并不是没有最小二乘解，而是数据只约束了直线在一个输入位置的高度，无法确定斜率。

处理一组数据时，应区分三个层次：先确认参数是否使指定目标函数最小，再看残差反映了怎样的近点误差，最后判断模型是否还会预定用途。参数唯一地出关键差异来自 $S_{xx}>0$。

结果检验、退化情形与工程解释

练习

某装置的三组输入输出记录为 $(0,1)$、$(1,1)$、$(2,3)$，其带截距最小二乘直线为 $\hat{y}=2/3+x$。列出拟合值和残差，核验残差和与均值点性质；求输入 $3/2$ 与输入 4 时的模型输出，分别说明属于区间内预测还是外推，并解释这些数值是否必然等于未来实测输出。答案统一置于讲义末尾。

结果检验、退化情形与工程解释

练习

对数据点 $(1,2)$、$(1,4)$ 作带截距直线最小二乘拟合。求全部最优参数、最小平方和以及输入 1 处的拟合值，并给出两条在输入 0 处输出不同的最优直线。由此判断：“只要最优参数不唯一，已有观测位置的拟合值就一定不唯一。”答案统一置于讲义末尾。